

EEE933 - Estudo de Caso 02: Avaliação e comparação do retorno médio de ações

Amanda Bomfim Moitinho, David Felipe Brochero Giraldo, Henrique Marques Cruz

28/09/2026

Resumo

Este estudo avalia qual, dentre cinco ações candidatas, tem maior potencial de retorno mensal para um investidor que pretende aplicar todo o capital em uma única ação. A partir dos preços de fechamento dos últimos 36 meses foram calculados 35 retornos mensais por ação. As médias foram comparadas por Análise de Variância (ANOVA) de um fator, com o teste de Kruskal-Wallis como checagem de robustez, seguida de comparações múltiplas de Tukey. As premissas foram verificadas via Shapiro-Wilk (normalidade), Fligner-Killeen (homogeneidade de variâncias) e Durbin-Watson (autocorrelação serial). A ANOVA rejeitou a igualdade das médias ($p < 0.001$). As ações A1 ($\bar{R} = 2.15\%$ ao mês, IC 95%: $[1.85; 2.45]$) e A3 ($\bar{R} = 1.87\%$ ao mês, IC 95%: $[1.59; 2.14]$) apresentaram retorno médio significativamente maior que o das demais, mas não diferiram entre si. Na comparação direta entre as duas, a diferença média foi de 0.28 p.p. ao mês a favor da A1 ($p = 0.187$, IC 95%: $[-0.14; 0.7]$), sem diferença detectável de volatilidade, e o teste de equivalência (TOST) com margem $\delta^* = 0.5$ p.p. não demonstrou equivalência. A1 apresentou a maior estimativa pontual de retorno, mas a potência das comparações múltiplas para detectar um efeito normalizado $d^* = 0.5$ é limitada, e o próprio teste de equivalência tem sensibilidade ainda menor para diferenças próximas a δ^* . Assim, os dados sustentam A1 e A3 como candidatas ao maior retorno médio, mas não fornecem evidência estatística suficiente para separá-las com segurança.

Introdução

Este estudo de caso avalia cinco ações da bolsa de valores a partir dos preços de fechamento dos últimos 36 meses. O investidor considerado dispõe de um montante fixo e pretende aplicá-lo integralmente em uma única ação, de modo que a análise precisa apontar qual das candidatas oferece o maior ganho mensal e, havendo mais de uma em destaque, reunir evidências que permitam escolher apenas uma. A resposta do experimento é o retorno mensal simples de cada ação, e o fator de interesse é o tipo de ação, com cinco níveis.

Desenho experimental

Descrição do problema

O objetivo é identificar a ação com maior retorno mensal médio dentre cinco candidatas, usando os retornos ao longo dos 36 meses como amostra do comportamento mensal de cada ação. Para cada ação i e mês j , a variável de resposta é o retorno mensal simples, em %:

$$R_{ij} = 100 \left(\frac{P_{ij}}{P_{i,j-1}} - 1 \right),$$

em que P_{ij} é o preço de fechamento da ação i no mês j . Pela simplificação do enunciado, o preço de abertura de um mês é igual ao fechamento do mês anterior, de modo que R_{ij} é exatamente o ganho percentual de quem compra a ação no início do mês j e a vende no fim desse mês. Como as ações podem ser adquiridas de forma fracionária, esse ganho percentual independe do montante investido e do preço unitário de cada ação, o

que torna os retornos das cinco ações diretamente comparáveis. Por esse mesmo motivo, os preços em si não são comparáveis entre ações e não foram utilizados como variável de resposta.

A média foi adotada como parâmetro de interesse porque o investidor busca o maior ganho mensal esperado. Os retornos das cinco ações foram modelados por um modelo de efeitos fixos de um fator (**Ação**, com $a = 5$ níveis e $n = 35$ observações por nível):

$$R_{ij} = \mu + \tau_i + \epsilon_{ij}, \quad \begin{cases} i = 1, \dots, 5 \\ j = 1, \dots, 35 \end{cases}, \quad \epsilon_{ij} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2),$$

em que μ é a média global e τ_i é o efeito da ação i [2]. O modelo de efeitos fixos é apropriado porque as cinco ações foram escolhidas pelo investidor, e as conclusões valem apenas para elas.

Como os cinco retornos de um mesmo mês são observados sob as mesmas condições de mercado, uma alternativa seria tratar o mês como bloco, de modo análogo ao pareamento na comparação de duas amostras. O pareamento, porém, só é vantajoso quando há correlação relevante entre as observações de um mesmo bloco. Essa correlação foi avaliada na Análise Exploratória e, por ser praticamente nula, optou-se pelo modelo de um fator, mais simples e com mais graus de liberdade residuais.

Hipóteses

A pergunta foi respondida em duas etapas, planejadas antes da análise.

Etapla 1 (ANOVA): verifica-se se existe diferença entre os retornos médios das ações:

$$\begin{cases} H_0 : \tau_i = 0, \forall i \in \{1, \dots, 5\} \\ H_1 : \exists \tau_i \neq 0 \end{cases}$$

Etapla 2 (comparações múltiplas): caso H_0 seja rejeitada, é preciso identificar quais ações diferem. Como não há uma ação de referência definida a priori (nenhuma das cinco é um “controle”), foram planejadas comparações de todos contra todos pelo método de Tukey [2, 6], com $K = a(a - 1)/2 = 10$ pares:

$$\begin{cases} H_0 : \mu_i = \mu_k \\ H_1 : \mu_i \neq \mu_k \end{cases} \quad \forall i < k.$$

O método de Dunnett seria apropriado se uma ação de referência tivesse sido definida antes da coleta. Como não há uma ação-controle definida a priori, escolhê-la após observar as médias caracterizaria uma hipótese formulada *post hoc* [5]. O método de Tukey permite comparar todos os pares mantendo o nível global de significância. As ações que não diferirem significativamente da ação de maior média amostral formam o grupo de candidatas ao maior retorno.

Evidências complementares: se mais de uma ação se destacar, conforme solicitado no enunciado, as duas primeiras colocadas serão comparadas diretamente por (i) teste t pareado das diferenças mensais, (ii) teste de equivalência por dois testes unilaterais (TOST) com margem δ^* [4], (iii) comparação das variâncias (volatilidade) pelo teste de Fligner-Killeen e (iv) frequência de meses com retorno negativo. O pareamento é natural nessa comparação, pois as duas ações são observadas nos mesmos 35 meses. Embora esse procedimento tenha sido definido antes da análise, as ações comparadas são escolhidas por terem as maiores médias amostrais, de modo que a diferença observada entre elas tende a estar superestimada; os resultados dessa etapa são, por isso, tratados como evidência complementar, e não como prova de superioridade. O teste t pareado é bilateral, uma vez que a direção da diferença entre as duas ações não foi fixada *a priori*.

O nível de significância adotado é $\alpha = 0.05$ em todas as etapas, e a potência desejada é $1 - \beta = 0.8$.

Tamanho de efeito mínimo relevante (δ^* e d^*)

Não há na literatura de finanças um valor consensual de diferença de retorno mensal a partir da qual uma ação deva ser preferida a outra, pois esse limiar depende do perfil do investidor, dos custos de transação e dos impostos. Os parâmetros de efeito mínimo relevante foram, portanto, definidos a priori, com base apenas em informações externas aos dados analisados.

Na escala dos retornos, adotou-se $\delta^* = 0.5$ ponto percentual ao mês ($\approx 6.2\%$ ao ano em regime composto). O valor é compatível com a ordem de grandeza dos custos de execução estimados para estratégias de negociação em ações, de 20 a 57 pontos-base [11]: diferenças de retorno menores que δ^* tenderiam a ser consumidas por custos de transação e impostos, desconsiderados nas simplificações do problema. Esse valor é utilizado como margem do teste de equivalência.

Para o cálculo da potência, seria necessária uma estimativa do desvio-padrão dos retornos obtida independentemente dos dados analisados (por exemplo, de um estudo piloto ou de dados históricos), que não está disponível. Adotou-se, por isso, o tamanho de efeito mínimo relevante normalizado, $d^* = \delta^*/\sigma = 0.5$, que corresponde ao efeito de magnitude “média” da convenção de Cohen [9, 10]. Nessa formulação, a potência depende apenas de d^* , n e α , e não de uma estimativa de σ . Ressalta-se que as convenções de Cohen são genéricas e não específicas para retornos financeiros, de modo que ambos os valores devem ser entendidos como referências para ancorar a análise, e não como limiares de decisão estabelecidos.

Os dois valores, embora apresentados em escalas distintas, não são equivalentes: δ^* é uma margem absoluta em pontos percentuais ao mês, enquanto d^* é um número de desvios-padrão. Traduzir um no outro exige o desvio-padrão que se pretende detectar, de modo que a relação entre as escalas só pode ser estabelecida depois de estimada a variabilidade dos retornos, o que é feito na seção de potência.

```
delta_star <- 0.5 # delta*: margem de equivalência, em p.p. ao mês
d_star     <- 0.5 # d*: efeito mínimo relevante normalizado (Cohen)
```

Descrição da coleta e consolidação dos dados

O arquivo `DadosAcoesGrupoA.csv` contém 36 linhas e 5 colunas, sem cabeçalho, com os preços de fechamento mensais de cada ação (colunas), ordenados do mês mais recente para o mais antigo (linha 1 = mês anterior ao atual). As colunas foram nomeadas A1 a A5, na ordem em que aparecem no arquivo.

Inversão da série: como o retorno de um mês depende do preço do mês anterior, a série foi invertida para a ordem cronológica antes do cálculo. Sem essa inversão, os retornos seriam calculados no sentido oposto e uma ação em alta pareceria estar em queda. Com 36 preços obtêm-se $n = 35$ retornos por ação. O número de meses não foi escolhido pela equipe, e sim fixado pelo enunciado, de modo que não houve cálculo de tamanho amostral para dimensionar a coleta. A análise de potência apresentada adiante avalia a sensibilidade do estudo para as diferenças de interesse.

Suposições explícitas: (i) conforme o enunciado, o preço de abertura de cada mês é igual ao fechamento do mês anterior e as ações podem ser adquiridas de forma fracionária; (ii) os preços fornecidos não incluem dividendos, desdobramentos ou custos de transação, de modo que os retornos calculados são retornos brutos de preço.

Análise Exploratória

Os dados foram carregados e consolidados conforme descrito no Planejamento do Experimento:

```
precos <- read.csv("DadosAcoesGrupoA.csv", header = FALSE)
names(precos) <- paste0("A", 1:ncol(precos))

# Arquivo ordenado do mês mais recente para o mais antigo: inverter
precos <- precos[nrow(precos):1, ]
P <- as.matrix(precos)
```

```
# Retornos mensais simples (%)
ret <- 100 * (P[-1, ] / P[-nrow(P), ] - 1)
n <- nrow(ret)

df <- data.frame(
  Mes = rep(1:n, times = ncol(ret)),
  Acao = factor(rep(colnames(ret), each = n)),
  Ret = as.vector(ret)
)
```

A Tabela 1 resume as estatísticas descritivas dos retornos mensais por ação.

```
ic <- t(apply(ret, 2, function(x) t.test(x)$conf.int))
resumo <- data.frame(Acao = colnames(ret),
  Media = colMeans(ret),
  IC95 = sprintf("%.3f; %.3f", ic[, 1], ic[, 2]),
  DP = apply(ret, 2, sd),
  Mediana = apply(ret, 2, median),
  Min = apply(ret, 2, min),
  Max = apply(ret, 2, max),
  MesesNeg = colSums(ret < 0))
knitr::kable(resumo, digits = 3, row.names = FALSE,
  caption = "Estatísticas descritivas dos retornos mensais (%) por ação")
```

Tabela 1: Estatísticas descritivas dos retornos mensais (%) por ação

Acao	Media	IC95	DP	Mediana	Min	Max	MesesNeg
A1	2.147	[1.847; 2.446]	0.871	2.243	-0.547	3.881	1
A2	-0.464	[-0.848; -0.081]	1.116	-0.445	-2.238	1.486	23
A3	1.869	[1.593; 2.145]	0.803	2.036	-0.274	3.399	1
A4	0.359	[-0.045; 0.762]	1.174	0.309	-1.923	3.301	15
A5	0.196	[-0.166; 0.558]	1.053	0.213	-2.112	2.332	13

A Figura 1 mostra a evolução dos preços normalizados pelo primeiro mês da série, e a Figura 2 ilustra a distribuição dos retornos mensais por ação.

```
Pn <- sweep(P, 2, P[1, ], "/" ) * 100
dfP <- data.frame(Mes = rep(0:n, times = ncol(P)),
  Acao = rep(colnames(P), each = n + 1),
  Preco = as.vector(Pn))
ggplot(dfP, aes(x = Mes, y = Preco, colour = Acao)) +
  geom_line(linewidth = 0.8) +
  labs(x = "Mês", y = "Preço normalizado", colour = "Ação") +
  theme_minimal()

ggplot(df, aes(x = Acao, y = Ret, fill = Acao)) +
  geom_boxplot(alpha = 0.6, outlier.shape = NA) +
  geom_jitter(width = 0.1, alpha = 0.6) +
  stat_summary(fun = mean, geom = "point", colour = "red", size = 3) +
  geom_hline(yintercept = 0, linetype = 2) +
  labs(y = "Retorno mensal (%)", x = NULL) +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 1: Preços de fechamento normalizados pelo primeiro mês da série (base 100)




Figura 2: Retornos mensais por ação (pontos vermelhos: médias)

Duas ações, A1 e A3, apresentam tendência de alta consistente, com retornos médios próximos de 2% ao mês e apenas 1 e 1 mês(es) de retorno negativo em 35, respectivamente. A A2 tem média negativa, enquanto A4 e A5 oscilam em torno de zero. As dispersões são da mesma ordem de grandeza (desvios-padrão entre 0.8 e 1.17 p.p.), e os boxplots são aproximadamente simétricos, sem *outliers* evidentes. Os intervalos de confiança de 95% das médias distinguem os dois grupos: em A1 e A3 o intervalo está inteiramente acima de zero, o intervalo de A2 está inteiramente abaixo, e os de A4 e A5 contêm zero, de modo que a média destes dois últimos não se distingue de um retorno mensal nulo.

A Tabela 2 apresenta a correlação entre os retornos mensais das ações, que indica se o pareamento por mês seria vantajoso.

```
knitr::kable(cor(ret), digits = 2,
              caption = "Correlação entre os retornos mensais das ações")
```

Tabela 2: Correlação entre os retornos mensais das ações

	A1	A2	A3	A4	A5
A1	1.00	0.01	-0.06	0.07	-0.08
A2	0.01	1.00	-0.06	-0.10	0.16
A3	-0.06	-0.06	1.00	0.06	0.09
A4	0.07	-0.10	0.06	1.00	-0.05
A5	-0.08	0.16	0.09	-0.05	1.00

As correlações são baixas (em módulo, no máximo 0.16), ou seja, as ações não respondem de forma comum a um “efeito de mercado” mensal. O mês, portanto, não é uma fonte relevante de variabilidade compartilhada, e tratá-lo como bloco não reduziria a variância residual. Isso justifica o uso do modelo de um fator definido no Desenho experimental.

Análise Estatística

Validação das premissas do modelo

O modelo da ANOVA pressupõe resíduos (1) independentes, (2) com variância homogênea entre as ações e (3) normalmente distribuídos. Embora a ANOVA seja relativamente robusta a violações moderadas de normalidade e de homocedasticidade quando o delineamento é balanceado [2], como neste caso (35 observações por ação), essas premissas foram verificadas. O modelo de efeitos fixos foi ajustado aos dados para permitir a inspeção dos resíduos:

```
modelo <- aov(Ret ~ Acao, data = df)

par(mfrow = c(1, 2), mar = c(4, 4, 1, 1))
qqPlot(modelo$residuals, pch = 16, las = 1, id = FALSE,
        xlab = "Quantis da Normal", ylab = "Resíduos")
plot(modelo$fitted.values, modelo$residuals, pch = 16, las = 1,
      xlab = "Valores ajustados", ylab = "Resíduos")
abline(h = 0, lty = 2)

shapiro.test(modelo$residuals)

##
## Shapiro-Wilk normality test
##
## data:  modelo$residuals
## W = 0.9965, p-value = 0.96
```




Figura 3: Gráfico quantil-quantil dos resíduos (esquerda) e resíduos em função dos valores ajustados (direita)

```
fligner.test(Ret ~ Acao, data = df)
```

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: Ret by Acao
## Fligner-Killeen:med chi-squared = 7.7931, df = 4, p-value = 0.09946
```

Normalidade. Os resíduos não apresentam desvio relevante da normalidade (Shapiro-Wilk, $p = 0.96$), e os pontos do gráfico quantil-quantil permanecem dentro da banda de confiança.

Homocedasticidade. O teste de Fligner-Killeen não rejeita a igualdade de variâncias entre as ações ($p = 0.099$), e o gráfico de resíduos por valores ajustados mostra dispersões semelhantes nos cinco níveis. O p -valor não é muito distante de α , mas as razões entre os desvios-padrão das ações são pequenas (no máximo ≈ 1.46), e o delineamento balanceado torna a ANOVA robusta a diferenças dessa magnitude. A premissa é consistente com os dados e justifica o uso de uma variância comum σ^2 , estimada pelo QM_{Res} , na ANOVA e nas comparações de Tukey.

Independência. É a premissa mais delicada, pois os dados são séries temporais, e retornos de meses consecutivos poderiam estar correlacionados (por exemplo, por tendências de mercado). O teste de Durbin-Watson [7] depende da ordenação das observações, e por isso foi aplicado a cada série de retornos em ordem cronológica, que é o fator suspeito de introduzir dependência.

```
set.seed(2026) # o p-valor do durbinWatsonTest é obtido por reamostragem
dw <- t(sapply(colnames(ret), function(a) {
  r <- durbinWatsonTest(lm(ret[, a] ~ 1))
  c(Autocorrelacao = r$r, DW = r$dw, p_valor = r$p)
}))
knitr::kable(dw, digits = 3,
              caption = "Teste de Durbin-Watson para cada série de retornos")
```

Tabela 3: Teste de Durbin-Watson para cada série de retornos

	Autocorrelacao	DW	p_valor
A1	0.005	1.976	0.968
A2	0.088	1.747	0.460
A3	-0.123	2.222	0.514
A4	-0.188	2.357	0.264
A5	-0.054	2.043	0.856

Nenhuma série apresenta autocorrelação de primeira ordem significativa (todos os p -valores acima de 0.05), e as estatísticas DW estão próximas de 2, valor esperado na ausência de autocorrelação. A dependência entre ações num mesmo mês também é desprezível, como mostrado na Tabela 2. Não há, portanto, evidência de violação da independência.

Resta uma premissa mais forte e não verificável com estes dados: a de que o comportamento dos retornos é estável no tempo, isto é, de que a média dos últimos 35 meses representa o retorno esperado para o próximo mês. Os testes comparam médias *históricas*, e a recomendação para o mês seguinte depende dessa hipótese.

Etapa 1: ANOVA

```
summary(modelo)

##              Df Sum Sq Mean Sq F value Pr(>F)
## Acao          4  178.9   44.73   43.54 <2e-16 ***
## Residuals    170  174.7    1.03
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

# Tamanho do efeito do fator
ss      <- summary(modelo)[[1]]
eta2    <- ss[1, "Sum Sq"] / sum(ss[, "Sum Sq"])
omega2  <- (ss[1, "Sum Sq"] - ss[1, "Df"] * ss[2, "Mean Sq"]) /
           (sum(ss[, "Sum Sq"]) + ss[2, "Mean Sq"])

# Checagem de robustez: alternativa não paramétrica à ANOVA
kruskal.test(Ret ~ Acao, data = df)

##
## Kruskal-Wallis rank sum test
##
## data:  Ret by Acao
## Kruskal-Wallis chi-squared = 92.902, df = 4, p-value < 2.2e-16
```

A hipótese nula de que todas as ações têm o mesmo retorno médio é rejeitada ($F = 43.54$, $p < 0.001$), conclusão corroborada pelo teste de Kruskal-Wallis, que não depende da premissa de normalidade, embora teste diferenças de distribuição, e não especificamente de médias. Há, portanto, ao menos uma ação com retorno médio diferente das demais. A fração da variabilidade total dos retornos que o fator ação explica é de $\eta^2 = 0.506$ ($\omega^2 = 0.493$), valor que indica um efeito de grande magnitude sobre o retorno mensal.

Etapa 2: comparações múltiplas de Tukey

```
tuk      <- glht(modelo, linfct = mcp(Acao = "Tukey"))
tuk_CI   <- confint(tuk, level = 0.95)
tuk_CI
```

```
##
## Simultaneous Confidence Intervals
##
## Multiple Comparisons of Means: Tukey Contrasts
##
##
## Fit: aov(formula = Ret ~ Acao, data = df)
##
## Quantile = 2.7576
## 95% family-wise confidence level
##
## Linear Hypotheses:
##      Estimate   lwr      upr
## A2 - A1 == 0 -2.611021 -3.279192 -1.942850
## A3 - A1 == 0 -0.277662 -0.945832  0.390509
## A4 - A1 == 0 -1.787909 -2.456080 -1.119738
## A5 - A1 == 0 -1.950474 -2.618645 -1.282303
## A3 - A2 == 0  2.333359  1.665188  3.001530
## A4 - A2 == 0  0.823112  0.154941  1.491283
## A5 - A2 == 0  0.660547 -0.007624  1.328718
## A4 - A3 == 0 -1.510247 -2.178418 -0.842076
## A5 - A3 == 0 -1.672812 -2.340983 -1.004641
## A5 - A4 == 0 -0.162565 -0.830736  0.505606

par(mar = c(4, 8, 2, 1))
plot(tuk_CI, main = "", xlab = "Diferença de retorno médio (p.p./mês)")
```




Figura 4: Intervalos de confiança simultâneos de 95% (Tukey) para as diferenças entre médias

```
ordem <- names(sort(colMeans(ret), decreasing = TRUE))
melhor <- ordem[1]
```

```

ci      <- tuk_CI$confint
nm      <- rownames(ci)
# Ações cujo IC da diferença em relação à melhor contém o zero
naodif  <- sapply(setdiff(colnames(ret), melhor), function(a) {
  k <- which(nm %in% c(paste(a, "- ", melhor), paste(melhor, "- ", a)))
  ci[k, "lwr"] <= 0 & ci[k, "upr"] >= 0
})
grupo   <- c(melhor, names(naodif)[naodif])
segunda <- ordem[ordem %in% grupo][2]

```

A ação de maior média amostral é a A1. O único intervalo de confiança envolvendo a A1 que contém o zero é o da diferença $A3 - A1$, ou seja, apenas a A3 não difere significativamente dela. Além disso, tanto a A1 quanto a A3 têm retorno médio significativamente maior que o de todas as demais ações, com diferenças entre 1.5 e 2.6 p.p. ao mês. As ações **A1** e **A3** se destacam, portanto, como candidatas ao maior retorno médio. Entre as demais, apenas a diferença $A4 - A2$ é significativa (a diferença $A5 - A2$ fica no limiar, com limite inferior do IC muito próximo de zero), o que não afeta a decisão.

Evidências complementares para a escolha entre A1 e A3

Como duas ações se destacaram, elas foram comparadas diretamente. Por serem observadas nos mesmos meses, a comparação foi feita com as diferenças pareadas $D_j = R_{A1,j} - R_{A3,j}$, pelo teste t pareado [1].

```

x <- ret[, melhor]; y <- ret[, segunda]; d <- x - y

# (i) Teste t pareado (bilateral) e tamanho de efeito
tD <- t.test(x, y, paired = TRUE)
tD

##
## Paired t-test
##
## data: x and y
## t = 1.3452, df = 34, p-value = 0.1875
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## -0.1418103 0.6971334
## sample estimates:
## mean difference
## 0.2776616

dD <- mean(d) / sd(d)
cat("Tamanho de efeito d =", round(dD, 2), "\n")

## Tamanho de efeito d = 0.23

# (ii) TOST: H0: |mu_D| >= delta* vs H1: |mu_D| < delta*
p_inf <- t.test(d, mu = -delta_star, alternative = "greater")$p.value
p_sup <- t.test(d, mu = delta_star, alternative = "less")$p.value
ic90 <- t.test(d, conf.level = 0.90)$conf.int
c(p_inferior = p_inf, p_superior = p_sup)

## p_inferior p_superior
## 0.0003134829 0.1444921545

ic90

## [1] -0.07135899 0.62668212

```

```
## attr("conf.level")
## [1] 0.9

# (iii) Comparação das variâncias (volatilidade)
fk <- fligner.test(list(x, y))
fk

##
## Fligner-Killeen test of homogeneity of variances
##
## data: list(x, y)
## Fligner-Killeen:med chi-squared = 0.046521, df = 1, p-value = 0.8292

# Premissa de normalidade das diferenças pareadas (teste t pareado e TOST)
shapiro.test(d)

##
## Shapiro-Wilk normality test
##
## data: d
## W = 0.9734, p-value = 0.543

# (iv) Potência do TOST: as duas hipóteses nulas são rejeitadas quando
# |D| < delta* - t_a * se, com D ~ N(mu_D, se)
pot_tost <- function(nn, muD) {
  se <- sd(d) / sqrt(nn)
  ta <- qt(0.95, nn - 1)
  pnorm((delta_star - ta * se - muD) / se) -
  pnorm((-delta_star + ta * se - muD) / se)
}
c(zero = pot_tost_zero <- pot_tost(n, 0),
  observada = pot_tost_obs <- pot_tost(n, mean(d)))

## zero observada
## 0.5355022 0.2507755

icx <- t(rbind(t.test(x)$conf.int, t.test(y)$conf.int))
knitr::kable(data.frame(
  Acao = c(melhor, segunda),
  Media = c(mean(x), mean(y)),
  IC95 = sprintf("[%f; %f]", icx[, 1], icx[, 2]),
  DP = c(sd(x), sd(y)),
  Media_DP = c(mean(x) / sd(x), mean(y) / sd(y)),
  MesesNeg = c(sum(x < 0), sum(y < 0)),
  digits = 3, row.names = FALSE,
  caption = paste0("Comparação entre ", melhor, " e ", segunda))
```

Tabela 4: Comparação entre A1 e A3

Acao	Media	IC95	DP	Media_DP	MesesNeg
A1	2.147	[1.847; 1.593]	0.871	2.465	1
A3	1.869	[2.446; 2.145]	0.803	2.327	1

(i) **Diferença de médias.** A diferença média estimada é de 0.28 p.p. ao mês a favor da A1, com tamanho de efeito pequeno ($d = 0.23$), e o teste t pareado não a considera significativa ($p = 0.187$; IC 95%: $[-0.14; 0.7]$).

O resultado é consistente com o obtido pelo método de Tukey. As diferenças pareadas não apresentam desvio relevante da normalidade (Shapiro-Wilk, $p = 0.543$), premissa do teste t pareado e do TOST.

(ii) **Equivalência.** A não rejeição em (i) não permite afirmar que as ações são equivalentes, e por isso foi realizado o TOST. O teste inferior rejeita sua hipótese nula ($p = 3.1 \times 10^{-4}$), fornecendo evidência de que a diferença média não é menor ou igual a $-\delta^*$. Já o teste superior não rejeita sua hipótese nula ($p = 0.144$). De forma equivalente, o IC de 90% $([-0.07; 0.63])$ não está contido em $[-\delta^*; \delta^*]$. Portanto, os dados sustentam não-inferioridade de A1 em relação a A3 para a margem de 0.5 p.p., mas **não sustentam equivalência** entre as duas ações. Esse resultado precisa ser lido junto com a potência do TOST, calculada acima: com 35 meses, a probabilidade de declarar equivalência seria de apenas 53.6% mesmo que a diferença verdadeira fosse nula, e de 25.1% se fosse a observada. A ausência de equivalência neste experimento decorre, portanto, em boa parte, da baixa sensibilidade do teste perto da margem, e não constitui evidência de que as duas ações difiram de forma relevante. Como o intervalo ainda inclui diferenças positivas de até aproximadamente 0.6 p.p. ao mês, não é possível determinar, com este experimento, se a diferença real é pequena ou se A1 apresenta alguma vantagem dentro dessa margem.

(iii) **Risco.** Como o investidor aplica todo o capital em uma única ação, a volatilidade também é relevante para a decisão. O teste de Fligner-Killeen não indica diferença entre as variâncias das duas ações ($p = 0.829$), e as razões média/desvio-padrão são muito próximas (Tabela 4). O teste ignora o pareamento, o que é aceitável aqui dada a correlação praticamente nula entre as duas séries (Tabela 2).

(iv) **Meses com perda.** As duas ações tiveram retorno negativo em apenas 1 e 1 dos 35 meses, respectivamente, de modo que esse critério também não as distingue.

Potência do teste

A potência foi calculada *a priori* para o efeito normalizado d^* definido no Desenho experimental, e não a partir do efeito observado ou de uma estimativa de σ obtida dos mesmos dados, pois a avaliação *a posteriori* da probabilidade do erro tipo II é uma abordagem inadequada [1, 8]. Na escala normalizada, os cálculos são feitos com desvio-padrão unitário e diferença igual a d^* .

Foram realizados três cálculos [3]. O primeiro refere-se à ANOVA, considerando o cenário conservador em que apenas duas ações diferem por d^* , com desvios simétricos em relação à média global e as demais sem efeito, $\tau = \{-d^*/2, d^*/2, 0, 0, 0\}$. O segundo refere-se às comparações entre pares, usando a correção de Bonferroni ($\alpha_{aj} = \alpha/K$, com $K = 10$) e a fórmula do teste t de duas amostras. Como a correção de Bonferroni é mais conservadora que o método de Tukey, esse cálculo fornece uma referência conservadora para a potência das comparações. O terceiro refere-se à comparação direta entre as duas ações de destaque pelo teste t pareado ($\alpha = 0.05$), com d^* expresso em unidades do desvio-padrão das diferenças pareadas.

```
tau <- c(-d_star/2, d_star/2, 0, 0, 0)
K <- 10

# ANOVA
potA <- power.anova.test(groups = 5, n = n, between.var = var(tau),
  within.var = 1, sig.level = 0.05)
npotA <- power.anova.test(groups = 5, between.var = var(tau),
  within.var = 1, sig.level = 0.05, power = 0.80)

# Comparações entre pares (Bonferroni)
potC <- power.t.test(n = n, delta = d_star, sd = 1,
  sig.level = 0.05 / K, type = "two.sample")
npotC <- power.t.test(delta = d_star, sd = 1, sig.level = 0.05 / K,
  power = 0.80, type = "two.sample")

# Comparação direta entre as duas ações de destaque (t pareado)
potP <- power.t.test(n = n, delta = d_star, sd = 1,
  sig.level = 0.05, type = "paired")
```

```
npotP <- power.t.test(delta = d_star, sd = 1,
                      sig.level = 0.05, power = 0.80, type = "paired")
```

```
potA; npotA; potC; npotC; potP; npotP
```

```
##
##      Balanced one-way analysis of variance power calculation
##
##      groups = 5
##      n = 35
##      between.var = 0.03125
##      within.var = 1
##      sig.level = 0.05
##      power = 0.3395887
##
## NOTE: n is number in each group

##
##      Balanced one-way analysis of variance power calculation
##
##      groups = 5
##      n = 96.43579
##      between.var = 0.03125
##      within.var = 1
##      sig.level = 0.05
##      power = 0.8
##
## NOTE: n is number in each group

##
##      Two-sample t test power calculation
##
##      n = 35
##      delta = 0.5
##      sd = 1
##      sig.level = 0.005
##      power = 0.219
##      alternative = two.sided
##
## NOTE: n is number in *each* group

##
##      Two-sample t test power calculation
##
##      n = 108.4834
##      delta = 0.5
##      sd = 1
##      sig.level = 0.005
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group

##
##      Paired t test power calculation
##
```

```
##          n = 35
##          delta = 0.5
##          sd = 1
##          sig.level = 0.05
##          power = 0.8195351
##          alternative = two.sided
##
## NOTE: n is number of *pairs*, sd is std.dev. of *differences* within pairs

##
##          Paired t test power calculation
##
##          n = 33.3672
##          delta = 0.5
##          sd = 1
##          sig.level = 0.05
##          power = 0.8
##          alternative = two.sided
##
## NOTE: n is number of *pairs*, sd is std.dev. of *differences* within pairs
```

Com $n = 35$ meses, a potência da ANOVA para detectar um efeito normalizado $d^* = 0.5$ entre duas ações é de apenas 34%, e seriam necessários 97 meses por ação para atingir 80%. Nas comparações múltiplas entre pares, a potência é de $\approx 21.9\%$, e seriam necessários cerca de 109 meses. A não rejeição de $\mu_{A1} = \mu_{A3}$ pelo método de Tukey reflete, em parte, essa baixa sensibilidade, e não é evidência de igualdade.

A comparação direta pelo teste t pareado é mais sensível, por envolver um único teste ao nível $\alpha = 0.05$: sua potência para d^* é de 82% (seriam necessários 34 meses para 80%). Assim, se a diferença real entre A1 e A3 fosse de magnitude média, o teste pareado teria alta probabilidade de detectá-la. A não rejeição nesse teste, com tamanho de efeito observado pequeno ($d = 0.23$), indica que uma eventual vantagem da A1 tende a ser menor que um efeito de magnitude média, o que é coerente com o resultado do TOST: há evidência de não-inferioridade, mas não de equivalência nem de superioridade.

Em contraste, as diferenças entre as duas ações de destaque e as demais (aproximadamente 1.5 a 2.6 p.p.) são três a cinco vezes maiores que δ^* . Essas diferenças foram identificadas pelas comparações múltiplas de Tukey, que rejeitaram as respectivas hipóteses de igualdade. Assim, os dados fornecem evidência consistente para separar A1 e A3 do grupo formado por A2, A4 e A5.

Os três cálculos anteriores são feitos na escala normalizada, ao passo que a margem δ^* foi definida em pontos percentuais. Com o desvio-padrão das diferenças pareadas observado neste conjunto ($s_D = 1.22$ p.p.), a margem $\delta^* = 0.5$ p.p. corresponde a $d = 0.41$, enquanto $d^* = 0.5$ equivale a 0.61 p.p. ao mês. Os dois limiares não coincidem, e a margem que o experimento se propôs a resolver é a mais exigente dos dois.

```
# Sensibilidade na escala de delta*
mde_pareado <- power.t.test(n = n, sd = 1, sig.level = 0.05,
                           power = 0.80, type = "paired")$delta
pot_pareado_delta <- power.t.test(n = n, delta = delta_star, sd = sd(d),
                                  sig.level = 0.05, type = "paired")$power

# n minimo com potencia >= 0.80 supondo diferenca verdadeira nula
nn <- n
while (pot_tost(nn, 0) < 0.80) nn <- nn + 1

# Formula analitica da aula 7 [3]: n >= (t_a + t_b)^2 s^2 / (delta* - mu)^2
n_mathews <- function(alpha = 0.05, beta = 0.2, diff_mu = 0, tolmargin, s) {
  n <- 0
  rhs <- ((qnorm(1 - alpha) + qnorm(1 - beta)) * s / (tolmargin - diff_mu))^2
```

```

while (n < rhs) {
  n <- rhs
  rhs <- ((qt(1 - alpha, n - 1) + qt(1 - beta, n - 1)) * s /
    (tolmargin - diff_mu))^2
}
n
}
n_mat <- n_mathews(diff_mu = 0, tolmargin = delta_star, s = sd(d))

c(delta_em_dp      = round(delta_star / sd(d), 3),
  mde_pareado      = round(mde_pareado, 3),
  mde_em_pp        = round(mde_pareado * sd(d), 3),
  pot_pareado      = round(pot_pareado_delta, 3),
  pot_tost_zero    = round(pot_tost_zero, 3),
  pot_tost_obs     = round(pot_tost_obs, 3),
  n_para_tost      = nn,
  n_mathews        = round(n_mat, 1))

##   delta_em_dp   mde_pareado   mde_em_pp   pot_pareado pot_tost_zero
##         0.409         0.487         0.595         0.653         0.536
##   pot_tost_obs   n_para_tost   n_mathews
##         0.251         53.000         38.500

```

Com $n = 35$ meses, o menor efeito normalizado que o teste t pareado detecta com 80% de poder é $d = 0.49$, equivalente a 0.6 p.p. ao mês, valor superior à margem δ^* . A potência desse teste para uma diferença verdadeira de exatamente δ^* é de 65.3%, e a do TOST é de 53.6% se a diferença verdadeira for nula, caindo a 25.1% se for a observada; seriam necessários cerca de 53 meses para que o TOST atingisse 80% de poder supondo diferenças nulas. O experimento não tinha, portanto, sensibilidade suficiente para confirmar a equivalência dentro de δ^* nem para excluir uma vantagem de A1 de tamanho comparável à margem. Esses números dependem do desvio-padrão estimado nos próprios dados e servem como avaliação de sensibilidade, e não como dimensionamento a priori do experimento.

Comparação com a expressão analítica. O tamanho de amostra necessário para o TOST pode ser obtido diretamente pela expressão da aula 7, $n \geq (t_\alpha + t_\beta)^2 \hat{\sigma}^2 / (\delta^* - \Delta\mu)^2$ [3], que, com $\hat{\sigma} = s_D$ e $\Delta\mu = 0$, fornece 38.5 meses, valor menor que o obtido acima, que é a potência exata do procedimento efetivamente aplicado aos dados. A diferença se explica porque a expressão trata os dois testes unilaterais como independentes, ao passo que no TOST ambos são calculados com os mesmos dados e são perfeitamente negativamente dependentes, de modo que a rejeição simultânea das duas hipóteses nulas é mais exigente do que a expressão supõe. Os números usados na discussão são os da potência exata do procedimento efetivamente aplicado aos dados; a expressão analítica é registrada aqui para comparação com o dimensionamento da aula.

Conclusões e Recomendações

- Ao nível $\alpha = 0.05$, há forte evidência de que os retornos médios das cinco ações diferem ($p < 0.001$). As ações **A1** e **A3** têm retorno médio significativamente maior que o de A2, A4 e A5, que podem ser descartadas, mas não diferem significativamente entre si.
- Na comparação direta entre A1 e A3: (i) a A1 tem retorno médio 0.28 p.p. ao mês maior (≈ 4.1 p.p. ao ano em regime composto), mas a diferença não é estatisticamente significativa ($p = 0.187$); (ii) o TOST não demonstra equivalência, embora o teste unilateral correspondente forneça evidência de que A1 não seja inferior a A3 por mais de $\delta^* = 0.5$ p.p., com a ressalva de que esse teste tem sensibilidade reduzida para diferenças próximas à margem e, com 35 meses, não teria potência suficiente para confirmar a equivalência (seção de potência); (iii) as volatilidades não diferem significativamente ($p = 0.829$); (iv) ambas tiveram retorno negativo em apenas 1 e 1 dos 35 meses, respectivamente.
- **Implicação para a escolha:** A1 apresenta a maior média amostral e A3 apresenta a segunda maior,

mas a diferença de 0.28 p.p. ao mês não foi detectada como significativa pelo teste pareado nem pelo Tukey. Portanto, **os dados não permitem selecionar estatisticamente uma única entre A1 e A3 com base apenas no retorno médio**. Se o investidor for obrigado a escolher uma única ação, A1 seria a escolha baseada exclusivamente na maior estimativa pontual observada, mas essa escolha é descritiva e não representa uma demonstração estatística de superioridade. O retorno de um mês específico apresenta desvio-padrão de aproximadamente 0.9 p.p. para A1, valor maior que a diferença média observada entre as duas.

- **Recomendações para melhorar o experimento:** (i) aumentar o número de meses observados para cerca de 109, caso se deseje 80% de potência nas comparações múltiplas entre pares para d^* , ou para cerca de 53, caso o objetivo seja confirmar a equivalência dentro de δ^* ; séries mais longas, contudo, tornam mais forte a hipótese de estabilidade dos retornos no tempo, e os dois objetivos precisam ser equilibrados; (ii) obter, antes da análise, uma estimativa independente do desvio-padrão dos retornos (por exemplo, de dados históricos anteriores ao período analisado), que permita planejar o experimento diretamente na escala de δ^* ; (iii) definir a priori, junto com o investidor, a margem δ^* e um critério de decisão que combine retorno e risco, em vez de usar o risco apenas como critério de desempate; (iv) utilizar preços ajustados por dividendos e desdobramentos e descontar custos de transação e impostos, que podem ser da mesma ordem da diferença entre as duas melhores ações; (v) validar a recomendação fora da amostra, por exemplo escolhendo a ação com os meses $1, \dots, t$ e verificando seu retorno no mês $t + 1$, o que testa diretamente a pergunta sobre o *próximo* mês; (vi) caso uma série mais longa revele correlação entre as ações num mesmo mês, tratar o mês como bloco para remover essa fonte de variabilidade.

Referências

- [1] Montgomery DC, Runger GC. Applied Statistics and Probability for Engineers. 5th ed. Hoboken: John Wiley & Sons; 2010.
- [2] Montgomery DC. Design and Analysis of Experiments. 6th ed. Hoboken: John Wiley & Sons; 2005.
- [3] Mathews P. Sample Size Calculations: Practical Methods for Engineers and Scientists. Fairport Harbor: MMB; 2010.
- [4] Walker E, Nowacki AS. Understanding Equivalence and Noninferiority Testing. J Gen Intern Med. 2011;26(2):192-196.
- [5] Kerr NL. HARKing: Hypothesizing After the Results are Known. Pers Soc Psychol Rev. 1998;2(3):196-217.
- [6] Hothorn T, Bretz F, Westfall P. Simultaneous Inference in General Parametric Models. Biom J. 2008;50(3):346-363.
- [7] Campelo F. Lecture Notes on Design and Analysis of Experiments. Version 2.12; 2018. Disponível em: <http://git.io/v3Kh8>.
- [8] Hoenig JM, Heisey DM. The Abuse of Power: The Pervasive Fallacy of Power Calculations for Data Analysis. Am Stat. 2001;55(1):19-24.
- [9] Cohen J. Statistical Power Analysis for the Behavioral Sciences. 2nd ed. Hillsdale: Lawrence Erlbaum Associates; 1988.
- [10] Ellis PD. The Essential Guide to Effect Sizes. Cambridge: Cambridge University Press; 2010.
- [11] Novy-Marx R, Velikov M. A Taxonomy of Anomalies and Their Trading Costs. Rev Financ Stud. 2016;29(1):104-147. <https://doi.org/10.1093/rfs/hhv063>

Papéis da equipe

- Amanda Bomfim Moitinho: Verificadora
- David Felipe Brochero Giraldo: Relator
- Henrique Marques Cruz: Relator

Declaração sobre o uso de IA generativa e tecnologias assistidas por IA

Durante a preparação deste trabalho, os autores utilizaram o assistente de IA Claude (Anthropic) para apoiar a estruturação do código de análise estatística em R e a revisão do texto e da análise. Após o uso dessa ferramenta, os autores revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo do relatório.